

El proyecto está orientado a demostrar un flujo completo Extract - Transform - Load (ETL) con Python. Consiste en la exploración, transformación y limpieza de datos utilizando Pandas. La necesidad es procesar dos archivos CSV de fuentes originales (customer\_data.csv y sales\_data.csv) para convertirlos en un dataset limpio y estructurado. El objetivo es realizar un análisis de ventas que responda a requerimientos específicos de negocio, como la moda de pago, distribución por género y edad, y precios por categoría.

# ETL con Pandas para el análisis de ventas o Exploración, Transformación y Limpieza de Datos utilizando Pandas

**TIPO DE PROYECTO:**

Es un trabajo práctico orientado a demostrar un flujo completo Extract - Transform - Load (ETL) con Python. Consiste en la exploración, transformación y limpieza de datos utilizando Pandas

**ESPACIO CURRICULAR/MÓDULO:**

Base de Datos II

**EJES | UNIDADES CONCEPTUALES:**

Flujo completo ETL, Limpieza y enriquecimiento de datos con Pandas, Análisis Exploratorio de Datos (EDA) y visualizaciones, Carga a base de datos relacional (Load), Consultas y validación de datos mediante SQL

**PROBLEMÁTICA | NECESIDAD | CASO:**

La necesidad es procesar dos archivos CSV de fuentes originales (customer\_data.csv y sales\_data.csv) para convertirlos en un dataset limpio y estructurado. El objetivo es realizar un análisis de ventas que responda a requerimientos específicos de negocio, como la moda de pago, distribución por género y edad, y precios por categoría

**OBJETIVO GENERAL:**

Diseñar y documentar un pipeline ETL con Pandas que integre los datos de clientes y ventas para producir un dataset limpio, indicadores analíticos y su carga en una base de datos relacional.

**OBJETIVOS ESPECÍFICOS:**

1. Leer y verificar los datos de entrada.
2. Estandarizar, limpiar y unir las tablas de clientes y ventas.
3. Crear una columna derivada de segmentación por edad (age\_group).
4. Generar tablas resumen para responder a requerimientos específicos (Modo de pago por género y edad).
5. Exportar el dataset limpio a un archivo CSV.
6. Cargar los datos transformados a una base de datos relacional (MySQL).
7. Realizar un Análisis Exploratorio de Datos (EDA) generando gráficos simples (métodos de pago, precios por categoría)

**FUNDAMENTACIÓN | HIPÓTESIS:**

El proyecto busca demostrar las capacidades de Python y la librería Pandas para manejar y limpiar grandes volúmenes de datos. Es crucial preparar los datos (limpieza de valores, estandarización y unificación) antes de cargarlos a la base de datos o realizar cualquier análisis exploratorio. Hipótesis (Implícita): Al aplicar el flujo ETL, se podrán identificar insights de negocio accionables, como el predominio del efectivo como método de pago y las categorías que generan los tickets promedio más altos (Technology y Shoes)

**ACCIONES | RECURSOS | TIEMPO:**

Acciones Principales: 1. Extract: Lectura de ambos CSV en DataFrames. 2. Transform: Estandarización de nombres, conversión de fechas a datetime, limpieza de valores (unificación de género, tipificación numérica, anulación de valores negativos), unión de tablas (sales.merge(customers)), y creación de la columna derivada age\_group. 3. Load: Exportación del dataset limpio (etl\_clean.csv) y carga opcional a MySQL (esquema etl\_ventas, tabla ventas\_clientes\_clean). Recursos: Python 3.10+ (probado con 3.11), Librerías (Pandas, SQLAlchemy, etc.), JupyterLab o VS Code, MySQL, customer\_data.csv y sales\_data.csv.

**PRODUCTO FINAL | CONCLUSIONES | RESULTADOS ESPERADOS:**

Producto Final: El dataset curado outputs/etl\_clean.csv, el cuaderno principal TP\_ETL\_con\_Pandas.ipynb con el pipeline completo, el archivo etl\_sql.sql con DDL y consultas de verificación, y el informe informe\_ETL.md. Conclusiones/Insights: El efectivo (Cash) es el modo de pago global predominante (44.447 operaciones), incluso en el segmento joven-adulto (25-35 años). Las categorías Technology y Shoes concentran los tickets promedio más altos. Se identifica una oportunidad para promover canales digitales debido al alto uso de efectivo. Resultados Esperados: Validación exitosa de los cálculos tanto en Pandas como en las consultas SQL.